

# Realce de Imagens de Sensoriamento Remoto Baseado em Classes de Uso da Terra

Luis Maurano<sup>1</sup>, Ana Júlia Dias<sup>1\*</sup>, Andrés Velastegui-Montoya<sup>2,3\*</sup>, Camila Totti<sup>1\*</sup>,  
Marina Galdez<sup>1\*</sup>

<sup>1</sup>Divisão de Geoinformática e Observação da Terra – DIOTG

Instituto Nacional de Pesquisas Espaciais – INPE – Avenida dos Astronautas, 1758,  
12221-010 São José dos Campos - SP

<sup>2</sup>Facultad de Ingeniería en Ciencias de la Tierra, ESPOL Polytechnic University,  
P.O. Box 09-01-5863, Guayaquil, Ecuador

<sup>3</sup>Centro de Investigación y Proyectos Aplicados a las Ciencias de la Tierra (CIPAT),  
ESPOL Polytechnic University, P.O. Box 09-01-5863, Guayaquil, Ecuador

{luis.maurano, ana.dias, camila.andrade, marina.silva}@inpe.br  
dvelaste@espol.edu.ec

**Abstract.** An important activity for evaluating land use changes is selecting the images of interest from the range of available satellite product providers and preparing these images for the processing/extraction stages. In the preprocessing phase, improving the visual quality of the image through histogram manipulation techniques is quite common. This study aimed to develop enhancements in Landsat 9 satellite image enhancement based on land use classes for the central-northern region of Mato Grosso state using Python programming. Masks of land use classes were created for the application of distinct enhancements for each class.

**Resumo.** Atividade importante para avaliação das mudanças do uso da terra é seleção das imagens de interesse dentre a gama de provedores de produtos satelitários disponíveis atualmente e preparação destas imagens para as etapas de processamento/extracção das informações. Na fase de pré-processamento, a melhoria na qualidade visual da imagem, através de técnicas de manipulação de histograma, é bem usual. Este estudo teve por objetivo desenvolver, com uso de programas em linguagem Python, melhorias no realce de imagens do satélite Landsat 9 com base em classes de uso da terra para região centro norte do estado do Mato Grosso. Foram criadas máscaras de classes de uso da terra para aplicação de realces distintos para cada classe.

## 1. Introdução

As imagens de satélite representaram um avanço significativo na gestão do território, amplamente adotadas pela comunidade científica para estudos ambientais, riscos, planejamento urbano, hidrologia, gestão agrícola, entre outros [Deilami et al. 2018; García-Berná et al. 2020; Jacobson 2011; Mondini et al. 2021]. Proporcionam uma visão extensa e multitemporal da superfície terrestre, permitindo avaliar as alterações causadas por fenômenos naturais ou atividades antrópicas [Almeida et al. 2016; Diniz et al. 2019]. Devido ao grande volume de dados a serem gerenciados, as imagens satelitais demandam uma revisão nos processos de gerenciamento, incluindo armazenamento, disseminação, processamento e visualização.

Para a interpretação e análises das imagens satelitais, é necessário considerar vários elementos como a forma e tamanho dos objetos, padrões, tom, texturas, resolução espacial (JENSEN, 2014). Entretanto, um dos aspectos importantes é o contraste entre os alvos, vinculada a resolução radiométrica [Trung et al. 2023]. O contraste é determinado pela diferença na luminância refletida por duas superfícies adjacentes. Na percepção visual, o contraste é definido pela discrepância na cor e no brilho entre um objeto e outros ao seu redor. O sistema visual humano é mais sensível ao contraste do que à luminância absoluta, o que nos permite perceber o mundo de forma semelhante, independente das mudanças significativas nas condições de iluminação [Sharma and Khunteta 2016].

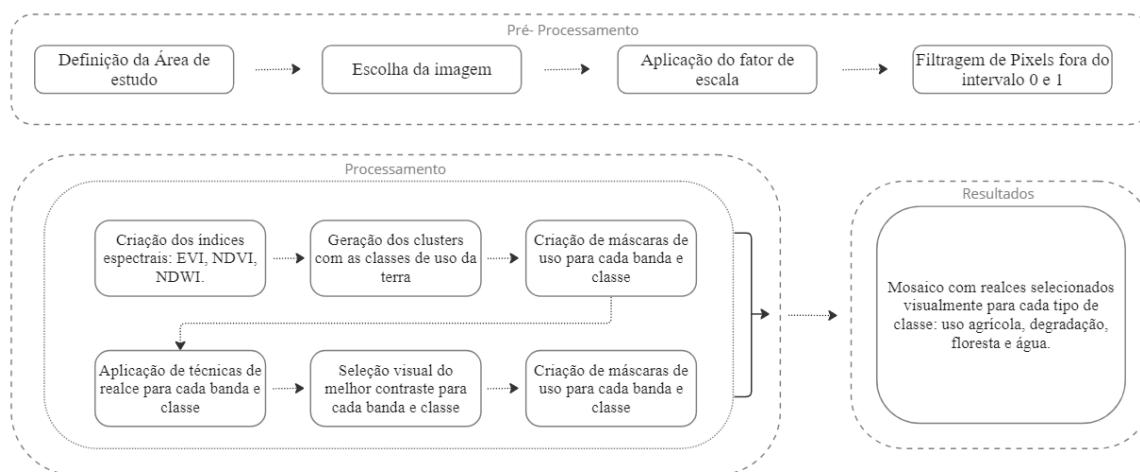
A melhora do contraste das imagens é essencial na área de processamento de imagens. Diversos métodos e algoritmos têm sido propostos para aprimorar a qualidade das imagens. Isso abrange uma ampla gama de processos, incluindo a redução de ruído, ajuste da faixa de níveis de cinza e suavização da imagem [Priyadarshini et al. 2014]. Os métodos de aprimoramento de imagem podem ser amplamente classificados nas categorias: lógica Fuzzy, métodos ideais e métodos baseados em histograma [Sharo T 2013]. Esses processamentos, influem na interpretação visual feita pelos pesquisadores.

Quando o contraste de uma imagem está concentrado em uma faixa específica, pode haver perda de informação nas áreas excessivamente e uniformemente concentradas. O desafio consiste em otimizar o contraste de uma imagem para representar todas as informações contidas nela. Existem diversas técnicas para lidar com esse problema, como a equalização global do histograma (GHE - General Histogram Equalization) e a equalização local do histograma (LHE - Local Histogram Equalization) [Sharo T 2013].

Este estudo desenvolveu em linguagem Python, métodos de aprimoramento do contraste de imagens de satélites por manipulação de histogramas específicos para classes de uso da terra, para facilitar a fase de interpretação visual dos objetos no processo de classificação das informações.

## 2. Material e métodos

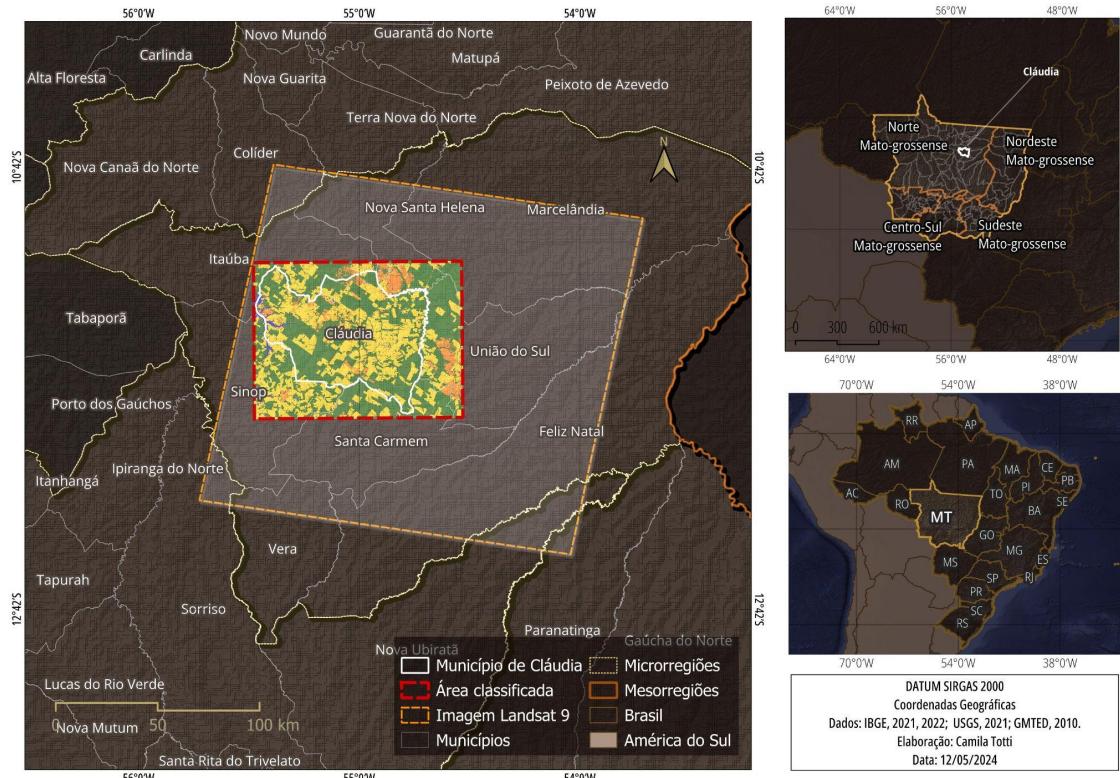
A metodologia do estudo compreendeu três fases (Figura 1): 1) Pré-Processamento: que considerou a definição da área de estudo, escolha da imagem de satélite, aplicação do fator de escala e filtragem de pixels; 2) Processamento: criação das máscaras de uso para cada banda e classe, baseado na aplicação de técnicas de realce; 3) Resultados: Geração do mosaico para cada tipo de classe.



**Figura 1: Fluxograma dos procedimentos.**

### 2.1 Área de estudo

A área de estudo selecionada para este projeto localiza-se no município de Cláudia, na microrregião de Sinop, no norte do estado do Mato Grosso. Situado entre as coordenadas 57º 0" e 52º0" Oeste a 15º 0' e 7º 0' Sul (Figura 2), Cláudia faz divisa com os municípios de Itaúba, Nova Santa Helena, Santa Carmem, Sinop e União do Sul. O município possui uma área aproximada de 3.843 km<sup>2</sup>, com uma população de 9.593 habitantes[IBGE 2022a].



**Figura 2: Localização da área de estudo.**

A região norte do estado do Mato Grosso experimentou, nas últimas décadas, uma rápida conversão da cobertura vegetal, onde grandes áreas de floresta desmatadas deram espaço à agricultura e pecuária extensiva, sendo considerada um dos principais polos de produção de grãos (soja, milho e arroz) e fibras (algodão) do estado [Francisco et al. 2017]. Segundo Rosan and Alcântara [2015] o desmatamento no município de Cláudia se intensificou na década dos anos 70, após a construção da rodovia BR-163, que atravessa de norte a sul os estados do Pará e Mato Grosso, conectando as cidades de Santarém e Cuiabá. Dentre as principais atividades que contribuíram para o desmatamento no município, estão a extração madeireira e a plantação de soja.

Entre os anos de 1998 e 2009, experimentou-se uma redução de 72% na atividade madeireira na região, atribuída tanto à intensa exploração da área, quanto pelo aumento da fiscalização e políticas de preservação [Lentini et al. 2003]. Em 2011, o município de Cláudia foi considerado área prioritária para prevenir, monitorar e controlar o desmatamento ilegal no bioma Amazônia, por meio do Art. 2º do Decreto nº 6.321/07. No ano de 2022, a área de estudo apresentou aproximadamente 54% de cobertura florestal primária, 8% de cobertura florestal secundária e 35% de uso agropecuário [Almeida et al. 2016].

Apesar da relevância do município na produção de grãos na região como a soja, o milho e arroz. A produção de arroz teve maior destaque no ano 2000, e apresentou

crescimento de área plantada até 2005. Porém, após esse período a produção de arroz perdeu relevância em termos de área, em comparação aos demais grãos produzidos. Desde 2010, os principais grãos cultivados em termos de área plantada são o arroz e a soja. Segundo os dados de produção agrícola municipal [IBGE 2022b], observa-se que o milho apresentou um crescimento relativamente constante a partir do ano 2000, apresentando, no entanto, uma área plantada relativamente menor do que a da soja. Para o ano 2022, a área plantada do milho correspondia a 86.000 ha, 16% menor que os 102.000 ha de soja plantada para o mesmo ano no município de Cláudia. A soja apresentou seu maior crescimento entre 2000 e 2005 e, mais recentemente, no período entre 2010 e 2015. Finalmente, o aumento da demanda por novas áreas para a agricultura, contribui no avanço da produção de soja no município, o que está relacionado ao desmatamento na região [Rosan and Alcântara 2015].

## 2.2 Material utilizado

A imagem utilizada foi obtida pelo satélite Landsat 9, equipado com o sensor OLI-2 (*Operational Land Imager 2*), corrigida atmosféricamente, ortorretificada com projeção Universal Transversa De Mercator (UTM) e datum WGS1984. Esta imagem apresenta resoluções espacial, radiométrica e temporal de 30 metros, 14 bits e 16 dias, respectivamente. A metodologia foi aplicada a uma fração da cena de órbita/ponto 226/68 correspondente à data 23/08/2023.

**Tabela 1: Bandas espectrais do satélite Landsat 9.**

Nome	Descrição	Comprimento de Onda
B1	Azul costeiro	0.43 - 0.45 µm
B2	Azul	0.450 - 0.51 µm
B3	Verde	0.53 - 0.59 µm
B4	Vermelho	0.64 - 0.67 µm
B5	Infravermelho próximo	0.85 - 0.88 µm
B6	SWIR 1	1.57 - 1.65 µm
B7	SWIR 2	2.11 - 2.29 µm

Foi selecionado o produto reflectância superfície (Coleção 2) disponível no acervo do portal Earth Explorer do USGS, para a geração de índices espectrais, classificação das principais classes de uso e cobertura da terra, geração das máscaras de uso e a posterior aplicação dos contrastes. A imagem selecionada corresponde ao

período de meados da estação seca na Amazônia brasileira. Por isso, espera-se que o solo das áreas agrícolas encontre-se exposto em função da colheita da última safra e da espera do plantio da próxima safra de 2023-2024. A vegetação natural também sofre consequências da estação seca, com secagem, que a torna mais suscetível à degradação por fogo. Estes fatores devem ser levados em consideração na etapa de extração e interpretação dos índices espectrais.

Todos os programas necessários para confecção das atividades, foram desenvolvidos em linguagem Python, versão 3.8 [Van Rossum and Drake 2009] e disponível no ambiente Anaconda [Anaconda 2023].

### 2.3. Métodos

As bandas das imagens obtidas são fornecidas em números digitais (DN) com valores inteiros de 16 bits. Portanto, fez-se necessária a conversão dos valores digitais de cada banda para os valores de reflectância originais em ponto flutuante, isto é, valores entre 0 e 1. Neste caso, o valor de cada pixel foi submetido a Equação 1, para as bandas 1 a 7 do Landsat 9, com fator multiplicativo = 0.0000275 e fator aditivo = -0.2 (USGS, 2020).

$$\rho_{BOA} = M_{Banda} \times DN + A_{Banda} \quad (\text{Equação 1})$$

Onde  $\rho_{BOA}$  = Reflectância de superfície em cada banda; DN = Número digital (16 bits: 1 a 65535);  $M_{Banda}$  = Fator multiplicativo (ou Fator de escala) de cada banda;  $A_{Banda}$  = Fator aditivo (offset) de cada banda.

A partir da normalização das bandas originais, foram calculados três índices espectrais (NDVI, EVI e NDWI) com o intuito de verificar diferentes contrastes a fim obter um maior destaque para os diferentes alvos da imagem para sua posterior clusterização. O Índice de Vegetação por Diferença Normalizada (*Normalized Difference Vegetation Index* - NDVI) evidencia diversos aspectos da vegetação, sendo utilizado para quantificar e avaliar a saúde da vegetação, permitindo a compreensão também de sua densidade (Equação 2).

$$NDVI = \frac{\rho_{IVP} - \rho_V}{\rho_{IVP} + \rho_V} \quad (\text{Equação 2})$$

Onde  $\rho_{IVP}$  corresponde à reflectância no infravermelho próximo (Banda 5) e  $\rho_V$  corresponde à reflectância no vermelho (Banda 4).

O NDVI é sensível ao efeito de fundo relacionado à reflectância do solo, isso é mitigado em outros índices como o *Índice De Vegetação Melhorado* (*Enhanced Vegetation Index* - EVI), similar ao NDVI, pode ser obtido pela Equação 3:

$$EVI = \frac{2.5(\rho_{IVP} - \rho_V)}{\rho_{IVP} + 6 \times \rho_V - 7.5 \times \rho_A + L} \quad (\text{Equação 3})$$

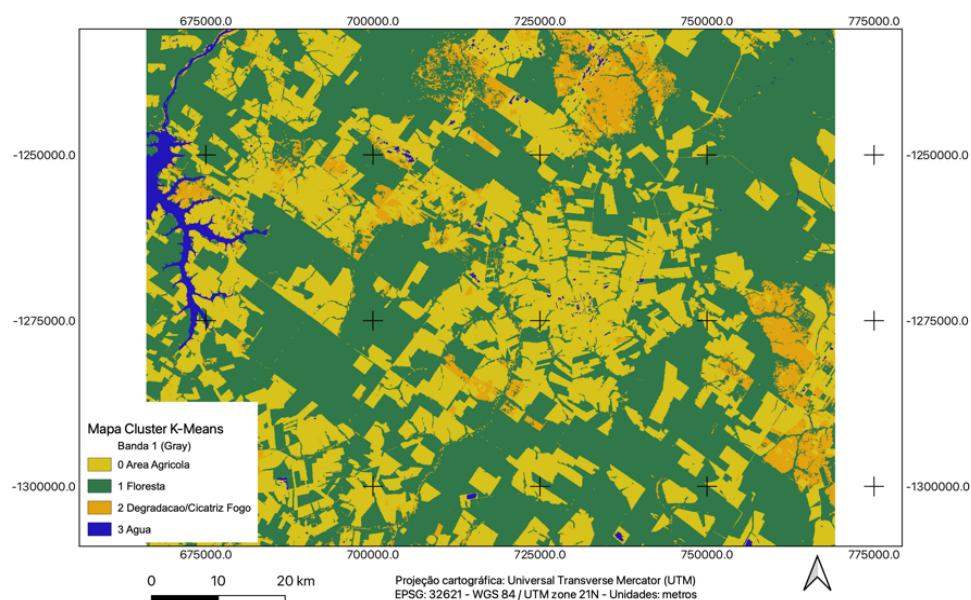
Onde  $\rho_{IVP}$  corresponde à reflectância no infravermelho próximo (Banda 5);  $\rho_V$  corresponde à reflectância no vermelho (Banda 4);  $\rho_A$  corresponde à reflectância no azul (Banda 2) e L é o fator de correção para ajustar o solo e o fundo do dossel.

O Índice de Água de Diferença Normalizada (Normalized Difference Water Index - NDWI), utilizado para realçar as feições da água em imagens de satélite, foi calculado com a Equação 4.

$$NDWI = \frac{\rho_{Vd} - \rho_{IVP}}{\rho_{Vd} + \rho_{IVP}} \quad (\text{Equação 4})$$

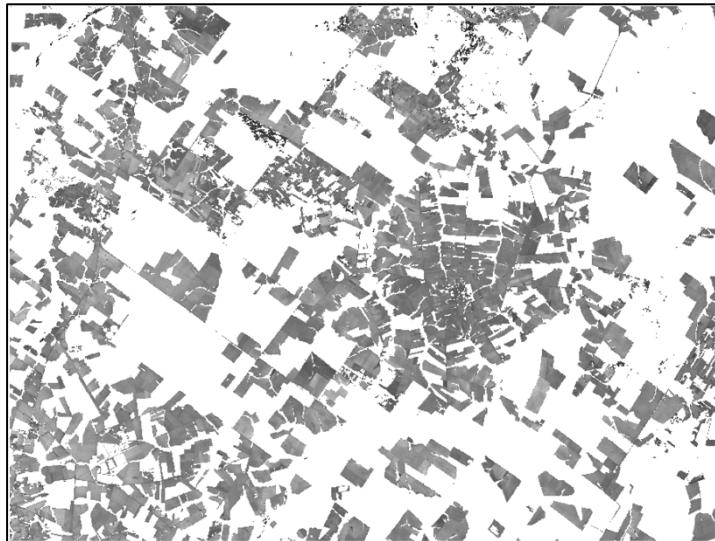
Onde  $\rho_{Vd}$  corresponde à reflectância no verde (Banda 3);  $\rho_{IVP}$  corresponde à reflectância no infravermelho próximo (Banda 5).

Foi realizada a classificação da imagem resultante do NDVI, com a finalidade de realçar e identificar as principais classes de uso e cobertura da terra. Optou-se por utilizar o método de classificação por agrupamento (*cluster*), a partir da aplicação do algoritmo K-Means [MacQueen 1967]. O K-Means apresenta uma implementação relativamente simples e eficaz, por esse motivo, ele é um dos algoritmos mais utilizados para a classificação de imagens [Luís et al. 2017]. Considerado um algoritmo não supervisionado, sua aplicação consiste na divisão de uma imagem em  $n$  grupos definidos pelo usuário, seguindo uma regra de maior dissimilaridade intergrupos e maior similaridade intragrupo possível. Foram indicados 4 clusters, visando separar as classes de floresta natural, uso agropecuário, água e degradação florestal/cicatriz de fogo. Em seguida, o método de classificação por cluster foi implementado em linguagem Python com uso da biblioteca open source Scikit Learn [Pedregosa Fabian et al. 2011], o resultado da classificação é apresentado na Figura 3.



**Figura 3: Mapa de uso e cobertura do solo gerado pelo método de cluster.**

Com base na imagem classificada foi possível gerar, máscaras das bandas para cada classe de uso e cobertura do solo, obtendo máscaras de agricultura, de água, de floresta e de degradação para as bandas 2 a 7, separadamente. Um programa em Python foi desenvolvido para a realização desta etapa. A Figura 4 mostra um exemplo da máscara de agricultura, na banda 5, recortada da banda original.



**Figura 4. Máscara agricultura da banda 5**

Para cada banda contendo as máscaras de uso foram aplicadas técnicas de realce de histograma com base nos métodos constantes da Tabela 2 [Câmara et al. 1996]. Um programa em linguagem Python foi desenvolvido para essa finalidade, que também fez uso da biblioteca Scikit Learn.

**Tabela 2: Técnicas de realces de histograma selecionadas**

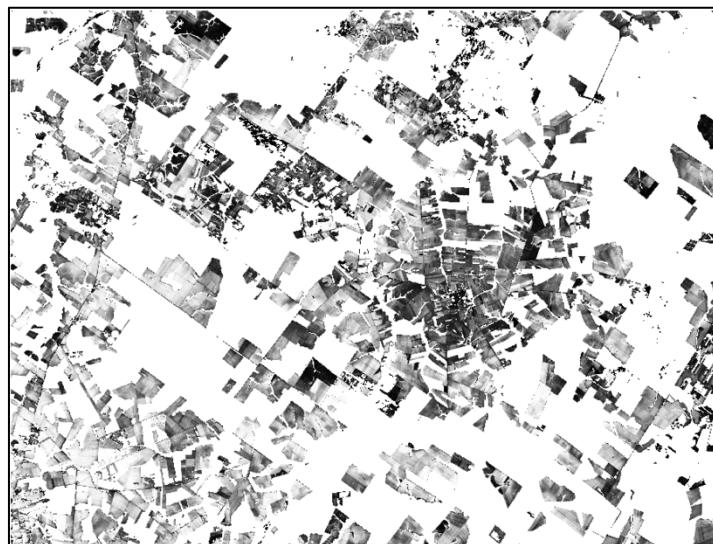
Tipo	Método
<b>Logarítmico</b>	$y = A \log(x + 1)$ y = novo valor de nível de cinza x = valor original de nível de cinza A = fator definido a partir dos limites mínimo e máximo da tabela, para que os valores estejam entre 0 e 255

<b>Min/Max</b>	$y = Ax + B$ x = valor original de nível de cinza; A = inclinação da reta (tangente do ângulo); B = fator de incremento, definido pelos limites mínimo e máximo fornecidos pela imagem.
----------------	--

<b>Equalização</b>	$y = (f.255)/Pt$ F = frequência acumulada para o nível de cinza xi Pt = população total (número total de "pixels")
--------------------	--

<b>Equalização Adaptativa</b>	Divide em pequenas regiões, e aplica a equalização
-------------------------------	--

A Figura 5 mostra um exemplo da máscara de agricultura, banda 5, após aplicação do realce por equalização do histograma.



**Figura 5. Máscara agricultura da banda 5 realçada.**

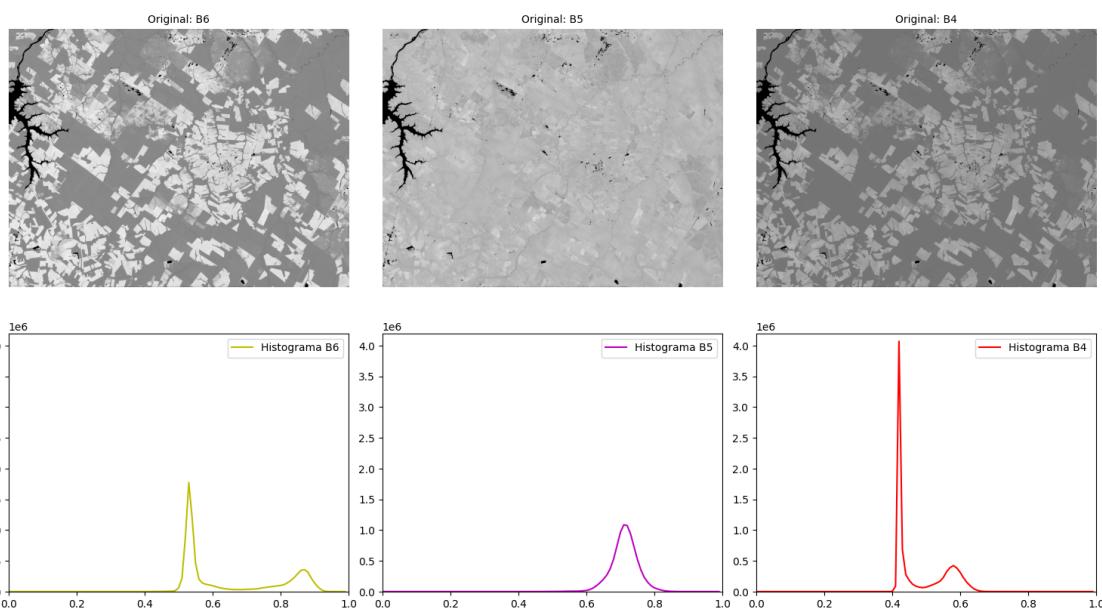
Após a etapa de geração das máscaras com realce, foi realizada a análise visual das imagens em composição colorida a partir dos vários realces gerados. Para o caso da análise dos realces das máscaras de agricultura, floresta e degradação, optou-se por composições coloridas das bandas 6R 5G 4B, por se tratarem de bandas com maior resposta espectral para estas classes. Para a inspeção do realce das máscaras de água foi utilizado uma composição 2R 3B 4G, por também possuírem maior resposta espectral para o alvo em análise.

Com uso do sistema QGIS foi construída a imagem combinada final contendo as máscaras com os devidos métodos de realce que apresentaram melhor qualidade visual, a saber: composição das bandas 6R 5G 4B com a técnica de realce por equalização para a classe de uso agrícola; composição das bandas 6R 5G 4B com a técnica de realce logarítmico para as classes de Degradação e de Floresta; e composição 2R 3B 4G com realce por equalização para a classe de água. A Figura 7 apresenta o resultado final da imagem composta.

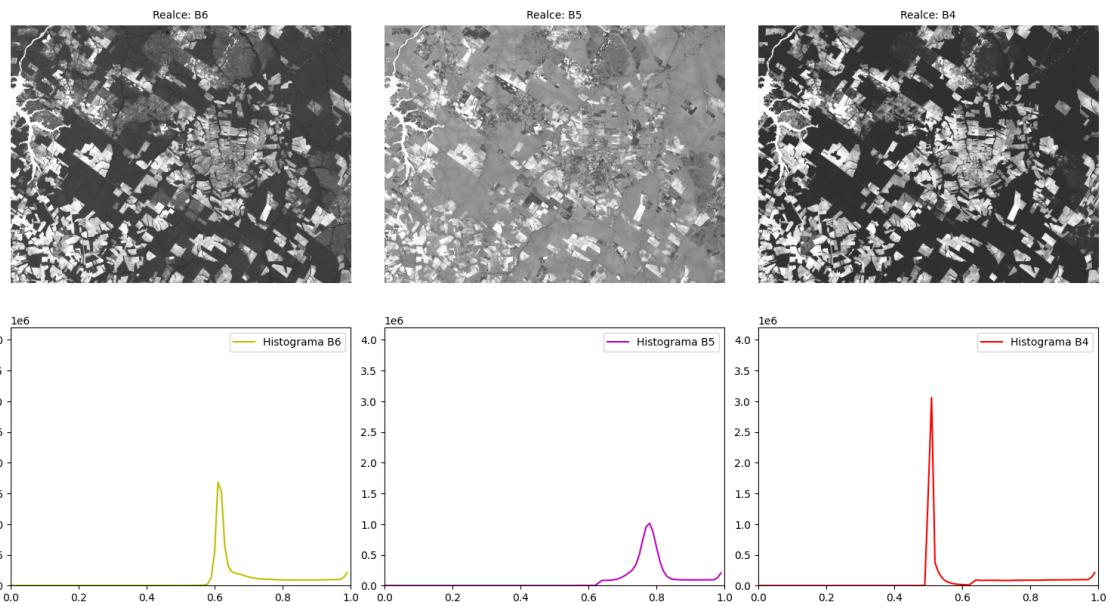
### 3. Resultados e discussões

A classificação gerada pela clusterização de alvos semelhantes pela banda de NDVI foi considerada satisfatória. Os demais índices espectrais EVI e NDWI, apesar de terem sido calculados e testados para a realização da classificação da imagem, não demonstraram resultados satisfatórios em relação à classificação da imagem realizada a partir do NDVI.

Analizando as bandas 6, 5 e 4 das classes de uso agrícola, floresta e degradação combinadas (Figura 6), observou-se que os métodos de realce de equalização para uso agrícola e de logarítmico para floresta e degradação, permitiu aumentar o contraste principalmente nas bandas 6 e 4. Dessa forma, há um menor pico do histograma, compensado com o aumento da largura através da redistribuição dos níveis de cinza (representados pela reflectância). Como existem dois picos na banda 6 e 4, o primeiro em cada banda foi atribuído às classes de degradação e floresta enquanto o segundo à classe de uso agrícola. Assim, uma vez que na agricultura foi aplicado o método de realce de equalização, que aumenta o contraste através da distribuição cumulativa, houve uma diminuição do pico do histograma que somado ao método logarítmico aplicado nas outras duas classes – que aumentou o brilho da imagem –, fez as curvas se aproximarem, e os dois picos se tornarem um.



**Figura 6a. Imagens e histogramas das bandas 6, 5 e 4 originais**



**Figura 6b. Imagens e histogramas das bandas 6, 5 e 4 realçadas**

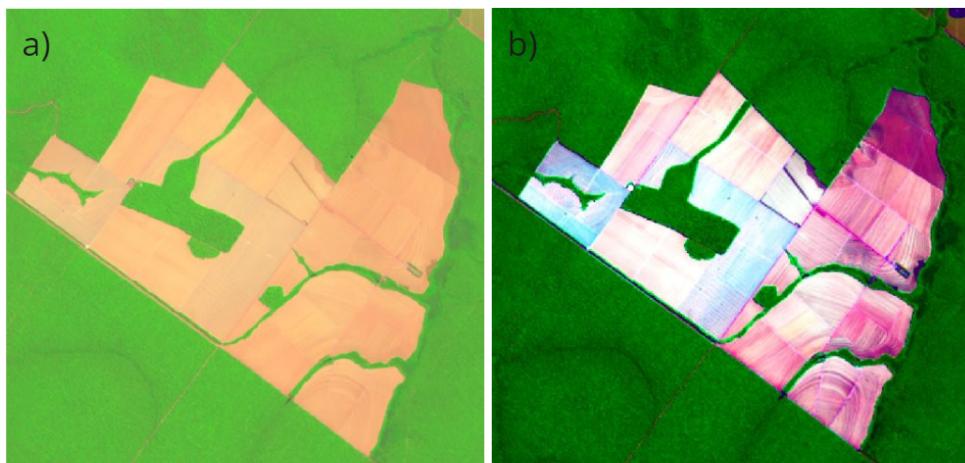
Na Figura 7, é possível observar a imagem original (7a) e a imagem final composta pelas classes realçadas (7b). A imagem final apresentou uma melhor distinção entre os alvos de degradação, floresta, água e uso agrícola em relação à imagem original. As classes de uso agrícola e água, que receberam a aplicação de contraste por equalização, puderam ser observadas com maior variação gradativa de cores no produto final. Já as classes de degradação e floresta, receberam o realce logarítmico e, ao final, foram representadas na imagem com maior contraste.



**Figura 7. Imagem original (a) e Imagem com composição final após aplicação dos realce por classes de uso (b)**

Os resultados da aplicação do contraste não apenas apresentaram diferenças de realce entre grandes classes, mas também diferenças significativas de contraste em alvos intraclasses. Quando analisadas as frações da classe de uso agrícola, foi possível perceber os diferentes padrões no solo, como áreas de palhada realçadas com intensidade na coloração azulada, bem como os diferentes trajetos realizados por

colheitadeiras ao longo dos talhões, representadas por padrões retilíneos e curvilíneos (Figura 8).



**Figura 8. Comparação entre a classe de uso agrícola anterior (a) e posterior (b) à aplicação do contraste.**

#### 4. Considerações finais

Este estudo teve por objetivo desenvolver, com uso de programas em linguagem Python, melhorias no realce de imagens do satélite Landsat 9 com base em classes de uso da terra para região centro norte do estado do Mato Grosso. Foram criadas máscaras de classes de uso da terra para aplicação de realces distintos para cada classe.

Para os testes, foi escolhida uma imagem do satélite Landsat 9/OLI-2 de agosto de 2023 em seu produto de reflectância de superfície (Coleção 2). Máscaras de uso da terra com 4 classes (floresta, degradação, água e agricultura) foram criadas com base em uma imagem classificada pelo valor de NDVI pelo método de agrupamento K-Means. Ao final, após processo de avaliação visual das várias técnicas de realces por manipulação de histograma desenvolvidas foram escolhidos a técnica de equalização para as classes de Uso agrícola e água, e logarítmico para as classes de Degradação e de Floresta.

Portanto, apesar da aplicação do contraste ter realçado os alvos da imagem, a resposta da imagem ao realce dependerá de características como a época do ano em que a imagem foi coletada, o ângulo de iluminação dos alvos, as bandas escolhidas e a área de estudo. Sendo a metodologia empregada nesta pesquisa, satisfatória para os autores, porém não tendo qualquer intenção de indicar melhores ou piores métodos de aplicação de contraste para condições generalizadas e distintas das utilizadas nesse estudo.

Todos códigos fontes desenvolvidos, além do conjunto de imagens utilizadas, podem ser encontrados no repositório: [https://github.com/LuisMaurano/Ser347\\_2024](https://github.com/LuisMaurano/Ser347_2024).

## 5. Agradecimentos

Os autores agradecem ao Eng. Ricardo Cartaxo M. Souza, servidor da Divisão de Observação da Terra e Geoinformática (DIOTG) do INPE pela disponibilização do programa Python que permitiu a classificação por cluster empregada neste estudo.

## Referências

- Almeida, C. A., Coutinho, A. C., Esquerdo, J. C. M., et al. (2016). High spatial resolution land use and land cover mapping of the Brazilian legal Amazon in 2008 using Landsat-5/TM and MODIS data | Mapeamento do uso e cobertura da terra na Amazônia Legal Brasileira com alta resolução espacial utilizando dados Landsat-5/TM. *Acta Amazonica*, v. 46, n. 3, p. 291–302.
- Anaconda, Inc. (2023). Anaconda Navigator.
- Câmara, G., Souza, R. C. M., Freitas, U. M. and Garrido, J. (1 may 1996). Spring: Integrating remote sensing and gis by object-oriented data modelling. *Computers & Graphics*, v. 20, n. 3, p. 395–403.
- Deilami, K., Kamruzzaman, M. and Liu, Y. (2018). Urban heat island effect: A systematic review of spatio-temporal factors, data, methods, and mitigation measures. *International Journal of Applied Earth Observation and Geoinformation*, v. 67, p. 30–42.
- Diniz, C., Cortinhas, L., Nerino, G., et al. (2019). Brazilian mangrove status: Three decades of satellite data analysis. *Remote Sensing*, v. 11, n. 7.
- Francisco, J., Antunes, G., Dalla, J. C., et al. (28 may 2017). Dinâmica do uso e cobertura da terra nas microrregiões de Sinop e Alto Teles Pires no Norte Mato-grossense. In *XVIII Simpósio Brasileiro de Sensoriamento Remoto (XVIII SBSR)*. . Galoá.
- García-Berná, J. A., Ouhbi, S., Benmouna, B., et al. (2020). Systematic mapping study on remote sensing in agriculture. *Applied Sciences (Switzerland)*, v. 10, n. 10.
- IBGE (2022a). Cidades e Estados.
- IBGE (2022b). Brasil / Mato Grosso / Cláudia.
- Jacobson, C. R. (2011). Identification and quantification of the hydrological impacts of imperviousness in urban catchments: A review. *Journal of Environmental Management*, v. 92, n. 6, p. 1438–1448.

- Lentini, M., Veríssimo, A. and Sobral, L. (2003). *Fatos Florestais da Amazônia 2003*.
- Luís, S., Gass, B., Galafassi, C. and Rodrigues De Vargas, R. (28 may 2017). Comparativo entre os algoritmos K-Means e ckMeans para mapeamento automatizado de uso do solo. In *XVIII Simpósio Brasileiro de Sensoriamento Remoto (XVIII SBSR)*. . Galoá.
- MacQueen, J. (1 jan 1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*. . University of California Press. <https://projecteuclid.org/ebooks/berkeley-symposium-on-mathematical-statistics-and-probability/Proceedings-of-the-Fifth-Berkeley-Symposium-on-Mathematical-Statistics-and/chapter/Some-methods-for-classification-and-analysis-of-multivariate-observations/bsmsp/1200512992>, [accessed on May 21].
- Mondini, A. C., Guzzetti, F., Chang, K.-T., et al. (2021). Landslide failures detection and mapping using Synthetic Aperture Radar: Past, present and future. *Earth-Science Reviews*, v. 216.
- Pedregosa Fabian, Michel, V., Grisel Olivier, et al. (2011). *Scikit-learn: Machine Learning in Python*. v. 12
- Priyadarshini, M., Sasikala, R. and Meenakumari, R. (2014). Novel approach for satellite image resolution and contrast enhancement using wavelet transform and Brightness Preserving Dynamic Histogram Equalization. In *Proceeding of the IEEE International Conference on Green Computing, Communication and Electrical Engineering, ICGCCEE 2014*.
- Rosan, T. M. and Alcântara, E. (2015). DETECÇÃO DE MUDANÇAS DE USO E COBERTURA DA TERRA NA AMAZÔNIA LEGAL MATOGROSSENSE: O ESTUDO DE CASO DO MUNICÍPIO DE CLÁUDIA (MT) Land Use Land Cover Change Detection in the Legal Amazon: A Case Study of Cláudia (Mato Grosso State, Brazil).
- Sharma, A. and Khunteta, A. (2016). Satellite image contrast and resolution enhancement using discrete wavelet transform and singular value decomposition. In *International Conference on Emerging Trends in Electrical, Electronics and Sustainable Energy Systems, ICETEESES 2016*.
- Sharo T, A. (2013). A Survey on Color Image Enhancement Techniques. *IOSR Journal of Engineering*, v. 03, n. 02.
- Trung, N. T., Le, X. H. and Tuan, T. M. (2023). Enhancing Contrast of Dark Satellite Images Based on Fuzzy Semi-Supervised Clustering and an Enhancement Operator. *Remote Sensing*, v. 15, n. 6.
- Van Rossum, G. and Drake, F. L. (2009). Python 3 Reference Manual. *Machine Learning*